

AstroNet-DR25-PyTorch 训练与架构详解

从 Kepler FITS、TCE 到双分支 1D-CNN

本文记录 2026-07-14 在 E5 双 RTX 3090 工作站上完成的 AstroNet-PyTorch 复现实验：先用 100 颗恒星跑通小闭环，再扩展到 1000 颗恒星、1164 个 TCE 完成 20 轮训练。文章从零解释网络架构、1D 卷积、Robovetter、FITS 与 TCE 的关系，以及 train、validation、test 为什么必须按恒星划分。基线始终只使用第一张 RTX 3090，第二张显卡不参与，以减少实验变量。

1. 先给初学者一个完整答案

今天跑通的模型确实采用传统机器学习中熟悉的三类数据集：

- **train**：训练集，用来计算损失、反向传播并修改网络权重。
- **validation**：验证集，用来选择模型、训练轮数、阈值和超参数，不直接修改权重。
- **test**：测试集，只在模型方案固定后做最终评价，不能反复拿来调模型。

但是天文时序数据还有一个比普通图片分类更容易踩坑的要求：**必须按 KIC 恒星编号分组划分**。同一颗恒星的全部季度FITS、全部TCE都只能进入其中一个集合，否则模型可能在训练集和测试集中同时见到同一颗星，形成数据泄漏。

实验分成两个阶段。第一阶段 pilot100 用于确认完整流程能够运行，共生成110个有标签TCE：

集合	TCE样本数	用途
train	66	更新模型权重
validation	22	选择最佳轮次和检查泛化
test	22	最终小样本流程检查


KIC跨集合泄漏数为0。

第二阶段M2把唯一恒星扩大到1000颗，并固定500颗纯候选体宿主和500颗纯假阳性宿主。由于一颗恒星可能含多个TCE，最终得到1164个训练样本：

集合	TCE样本数	候选体	假阳性
train	698	396	302
validation	233	132	101
test	233	132	101

两个阶段都严格按KIC分组，M2的 `kic_leakage_max_splits=1`，表示每颗恒星只出现在一个集合中。

从原始观测文件到一个 AstroNet 分类样本



一个 KIC 通常有14-18个FITS；一个 KIC也可能有多个TCE。

FITS提供亮度随时间的原始数值，TCE提供“按什么周期和中心时刻折叠”的事件坐标。

两者结合，才能为每个TCE生成一组固定长度的神经网络输入。

FITS、TCE、固定长度视图和模型之间的关系

2. FITS不是图片，TCE也不是文件

2.1 FITS是什么

FITS是天文学常用的数据容器格式。Kepler long-cadence FITS的核心不是一张给人看的照片，而是一张数值表，其中包括：

- **TIME**：每次观测的时间。
- **PDCSAP_FLUX**：经过Kepler管线校正的恒星亮度。
- **SAP_QUALITY**：该次观测可能存在何种质量问题的标记。
- 头部元数据：季度、目标编号、观测信息等。

Kepler主任务持续约4年，按Q0到Q17分成17个约90天的季度。不是所有恒星都有完整18段，因此一颗恒星通常对应约14到18个long-cadence FITS。

所以“10颗恒星发现170个FITS”的含义大致是：

$$10 \text{ 颗恒星} \times \text{平均17个季度文件} = \text{约170个FITS}$$

这不是170张分类图片，也不是170颗恒星。程序要把属于同一KIC的季度文件按时间拼接，才得到这颗恒星约4年的完整光变历史。

2.2 KIC是什么

KIC是Kepler Input Catalog编号，可以把它理解成Kepler观测目标的“恒星身份证号”。例如 **KIC 003120355** 表示一颗特定恒星。

同一个KIC可能存在多个周期不同的凌星信号。例如一颗多行星系统中，不同行星产生不同周期的亮度下降，因此同一颗恒星可以产生多个TCE。

2.3 TCE是什么

TCE是 Threshold Crossing Event, 即“超过检测阈值的事件”。Kepler搜索管线先在光变曲线中寻找重复的亮度下降。当一个周期性信号达到检测条件时, 就生成一条TCE记录。

TCE不是一份新的光变文件, 而是一组描述“如何在原始光变中定位这个事件”的参数, 主要包括:

字段	含义	在预处理中的作用
kepid	恒星KIC编号	找到该恒星的全部FITS
tce_plnt_num	该恒星上的事件序号	区分同一恒星的多个TCE
tce_period	周期, 单位天	决定按多长周期折叠光变
tce_time0bk	凌星中心历元	决定把哪个时刻对齐到相位0
tce_duration	事件持续时间, 单位小时	决定local视图放大多宽
MES等	多事件统计显著性	描述信号强弱, 不直接替代光变输入

FITS提供“亮度随时间怎么变化”, TCE提供“用什么周期、中心时刻和持续时间去观察这段变化”。两者缺一不可。

2.4 TCE、KOI和确认行星不是同一个概念

可以把它们看成逐级筛选:

原始恒星光变

- > 管线检测到周期信号: TCE
- > 通过进一步审查、值得跟踪: KOI
- > 被判为行星候选体: Planet Candidate
- > 经过额外证据确认: Confirmed Planet

TCE只是“机器检测到一个值得检查的周期事件”, 并不自动等于行星。星斑、食双星、背景污染、宇宙线、滚动带噪声和数据处理伪影都可能生成TCE。

3. 为什么要先去趋势和相位折叠

原始光变中, 行星凌星只是很短、很浅的下降。与此同时, 恒星自身会缓慢变亮变暗, 仪器也会引入长期趋势。

今天的复现按照Google AstroNet的思路处理:

1. 读取同一KIC的全部季度FITS。
2. 删除时间或亮度为非有限值的采样点。
3. 在大于0.75天的观测间隙处分段。
4. 对每段尝试多种B样条断点间距, 用BIC选择低频趋势。
5. 用原亮度除以样条趋势, 得到近似平坦的归一化光变。
6. 使用TCE的周期和历元进行相位折叠。
7. 生成global 2001点和local 201点两个固定长度向量。

所谓相位折叠，就是把许多个轨道周期叠在一起。假设周期为10天，Kepler观测了1000天，那么约100次可能的凌星会对齐到相位0附近。单次很弱的下降经过对齐后会更清楚。

相位时间可写成：

$$\text{folded_time} = ((\text{time} - \text{epoch} + \text{period}/2) \bmod \text{period}) - \text{period}/2$$

折叠结果位于 $[-\text{period}/2, \text{period}/2]$ ，预测凌星中心位于0。

4. AstroNet的输入到底是什么

AstroNet不直接把107,364个FITS文件逐个塞进网络。FITS经过拼接、去趋势、折叠和分箱后，每个TCE才变成一组固定长度输入。

4.1 global view: 2001点

global视图覆盖完整轨道周期，从 $-\text{period}/2$ 到 $+\text{period}/2$ 。它让模型看到：

- 中心主凌星以外是否还有次级食。
- 轨道其他相位是否存在异常下降。
- 整圈形状是否存在双星或恒星活动特征。
- 主事件相对完整周期的宽度和对称性。

官方配置使用2001个位置，分箱宽度为 $\text{period} / 2001$ 。

4.2 local view: 201点

local视图只观察中心凌星附近，范围约为中心左右各4个TCE持续时间。它放大：

- 凌星底部是平底还是V形。
- 入凌和出凌是否对称。
- 事件宽度是否合理。
- 中心附近是否有尖峰、孤立坏点或不稳定噪声。

local视图有201个位置，官方分箱宽度为 $0.16 \times \text{duration}$ 。

4.3 为什么要同时使用两个视图

只看global，单个凌星在2001点里可能过窄；只看local，又看不到轨道另一侧的次级食。因此双视图类似于医生同时看“全身片”和“局部放大片”。

两个视图都被归一化为中位数约0、最深点约-1。这样模型更关注形状，而不是仅仅记住绝对亮度尺度。

5. 图像CNN与1D-CNN有什么区别

5.1 图像中的2D卷积

普通灰度图像可以表示为：

[通道, 高度, 宽度]

常见的 3×3 卷积核同时沿上下和左右两个方向滑动。它一次查看相邻9个像素，可以逐层学出边缘、角点、纹理和物体形状。

5.2 光变曲线中的1D卷积

AstroNet输入是一条按相位排列的数值序列：

[通道, 序列长度]

这里没有“上下”和“左右”两个空间方向，只有时间或相位这一个顺序方向。长度5的1D卷积核每次查看连续5个位置，然后沿序列向前滑动。


2D 图像卷积与 1D 光变卷积的直观区别

图像 CNN：3 x 3 卷积核

0	1	2	3	4	5	6
7	8	9	0	1	2	3
4	5	6	7	8	9	0
1	2	3	4	5	6	7
8	9	0	1	2	3	4
5	6	7	8	9	0	1
2	3	4	5	6	7	8

同时沿高度和宽度滑动
学习边缘、角点、纹理

AstroNet：长度 5 的 1D 卷积核



只沿相位/时间轴滑动
学习下降沿、平底、V形和局部噪声

共同点：局部连接 + 权重共享。不同点：图像有两个空间方向，光变曲线只有一个顺序方向。

图像2D卷积与光变1D卷积

对一个输出通道，可以把计算简化解为：

```
output[i] = bias
+ w[0] * input[i-2]
+ w[1] * input[i-1]
+ w[2] * input[i]
+ w[3] * input[i+1]
+ w[4] * input[i+2]
```

真实网络同时有多个输入通道和输出通道，因此还要对通道求和。训练会自动调整这些权重，让某些卷积核对下降沿敏感、某些对V形敏感、某些对尖锐孤立噪声敏感。

5.3 二者的共同点


- 都使用局部连接：每个神经元只看附近一小段。
- 都使用权重共享：同一卷积核在不同位置复用。
- 都可以通过堆叠卷积层扩大感受野。
- 都常用ReLU引入非线性、用池化压缩长度并提高小位移鲁棒性。

5.4 为什么1D-CNN适合相位折叠光变

凌星、食双星和仪器伪影都表现为局部形状。1D-CNN不需要人工写出“V形程度”“下降沿斜率”等全部规则，而是可以从标注样本中学习有用的局部模式。

6. AstroNet双分支网络逐层拆解

AstroNet 的 global + local 双分支 1D-CNN



每个卷积块：Conv1D(kernel=5) + ReLU + Conv1D(kernel=5) + ReLU + MaxPool。
global 池化窗口5，local池化窗口7；模型总参数为 9,940,193。

global负责看整圈相位中的次级食、恒星变化等；**local**负责放大中心凌星的形状。


AstroNet双分支1D-CNN架构

6.1 教科书式逐层展开图应该怎样读


下面这张图把实际运行的PyTorch网络从左到右完全展开。图中的尺寸统一写成“通道数 x 序列长度”，不包含batch维。例如，global输入 **1 x 2001** 表示一条样本有1个输入通道、2001个相位格点；训练时若 batch size为64，送入网络的完整张量形状就是 **[64, 1, 2001]**。

AstroNet-DR25-PyTorch：逐层网络架构与张量尺寸

GLOBAL 分支：看完整相位周期，捕捉主凌星之外的上下文




LOCAL 分支：放大中心流量，保留下降沿、底部与上升沿的细节




张量标记：通道数 x 序列长度（不含batch维）

分类器：组合两种视野的证据



一个1D卷积核怎样工作：长度5的窗口只沿相位轴左右滑动



当前窗口：5个相邻相位格点

同一组权重会在每个位置重复使用（权重共享），窗口向右移动1格，就得到下一个位置的响应。
图像CNN的3 × 3卷积核沿高度、宽度两个方向滑动；这里的k=5只沿相位/时间这一个方向滑动。
第一层从亮度学习下降沿、上升沿等简单形状；后续层把简单形状组合成V形、U形和更复杂模式。

读图口诀

卷积 长度不变，逐层学习局部形状
通道变多 16 → 32 → 64 → 128 → 256
代表可识别的特征种类增加
池化 序列变短，感受野扩大
并容忍很小的相位偏移
双分支 global看上下文，local看凌星细节
最后合并证据进行分类

全网可训练参数：9,940,193 | 卷积核 k=5 | 卷积 stride=1 | 池化 stride=2

读这张图时，可以抓住四条线索：

1. **从左向右是数据流。** 蓝色global分支看完整相位周期，橙色local分支放大中心凌星；两者并行提取特征，之后才展平、拼接。
2. **序列长度逐渐缩短。** global从2001点缩到59个位置，local从201点缩到46个位置，主要是MaxPool造成的。
3. **通道数逐渐增加。** 通道可以理解成网络学习出来的“特征探测器种类”。早期通道可能响应下降沿、上升沿或尖峰，后期通道会组合出V形、U形、次级食等更复杂模式。
4. **最右边才做最终分类。** 两个分支合计得到16,576个数，经过4层512维全连接层，输出一个logit，再由sigmoid转换成0到1的AstroNet分数。

6.2 1D卷积核究竟是什么

传统图像CNN常见的 3×3 卷积核会同时沿图像的高度和宽度滑动。AstroNet处理的不是二维照片，而是一条按相位排列的光变序列，所以卷积核只沿一个方向滑动。本项目的 `kernel_size=5` 表示每次查看连续5个相位格点，而不是 5×5 的方块。

对第一层的某一个卷积通道，可以把一个位置的计算简写为：

$$y(t) = b + w(-2)x(t-2) + w(-1)x(t-1) + w(0)x(t) + w(1)x(t+1) + w(2)x(t+2)$$

这里的5个权重和一个偏置不是人工设定的，而是从训练数据中学习的。同一组权重会在2001点或201点的所有位置重复使用，这叫**权重共享**。因此，一个学会识别“凌星下降沿”的卷积核，无论下降沿落在序列的哪个位置，都可以产生响应。

严格地说，第一层以后每个位置不再只有一个亮度值，而是有许多通道。某个输出通道会同时读取所有输入通道在相邻5个位置的数值，再进行加权求和。网络越深，它看到的就越不是单个亮度点，而是前面各层已经提取出的形状组合。

卷积块中各操作的作用是：

- **第一层Conv1D：** 从相邻点学习局部变化，例如下降沿、上升沿、尖峰和平坦区域。
- **ReLU：** 把负响应截为0，保留被当前特征探测器激活的部分，并为网络引入非线性。
- **第二层Conv1D：** 把第一层的简单响应继续组合，例如形成V形、U形、非对称凹陷或短时伪影。
- **MaxPool1D：** 压缩序列长度，让后续神经元覆盖更大的原始范围，并降低对一两个相位格偏移的敏感程度。

这也解释了网络中“长度变短、通道变多”的总体趋势：位置分辨率逐步变粗，但可表示的特征类型逐步丰富。

6.3 一个卷积块是什么

本项目严格按Google官方配置实现，每个卷积块包含：

```
Conv1D(kernel_size=5)
-> ReLU
-> Conv1D(kernel_size=5)
-> ReLU
-> MaxPool1D
```

卷积使用same padding，所以卷积本身保持序列长度；池化使用valid方式，负责缩短序列。

6.4 global分支

阶段	通道数 x 长度	说明
输入	1 x 2001	完整轨道周期
Block 1	16 x 999	两层卷积，窗口5，池化5/步长2
Block 2	32 x 498	通道翻倍
Block 3	64 x 247	感受野继续扩大
Block 4	128 x 122	提取更高层组合模式
Block 5	256 x 59	最终global特征图
展平	15,104	256 x 59

6.5 local分支

阶段	通道数 x 长度	说明
输入	1 x 201	中心凌星放大图
Block 1	16 x 98	两层卷积，池化7/步长2
Block 2	32 x 46	第二组局部特征
展平	1,472	32 x 46

6.6 拼接与全连接分类器

```
global展平: 15,104
local展平: 1,472
拼接总计: 16,576
```

```
16,576 -> 512 -> 512 -> 512 -> 512 -> 1 logit
```

最后一个logit经过sigmoid后转成0到1的AstroNet分数。训练时使用 **BCEWithLogitsLoss**，它把sigmoid和二元交叉熵合并，数值更稳定。

模型可训练参数总数是 **9,940,193**。float32纯权重约40 MB；使用Adam训练时还要保存梯度与一阶、二阶动量，因此训练检查点和显存占用会更大，但对单张24 GB RTX 3090仍然非常小。

6.7 为什么没有直接照搬NASA FDL PyTorch代码

网上已有NASA Frontier Development Lab的PyTorch翻译版，可作为重要参考。但逐层核对发现，其公开 `astronet.py`：

- 只实现了3层512维隐藏全连接层，而Google官方配置要求4层。
- 有一处卷积后缺少ReLU。

所以本项目不是盲目复制第三方代码，而是以Google TensorFlow配置为最高标准，参考FDL实现并完成现代PyTorch校正。

7. MaxPool在一维网络里做什么

MaxPool1D(kernel=5, stride=2) 会在连续5个位置中保留最大激活，然后向前移动2格。这里保留的不是原始亮度最大值，而是卷积特征的最大响应。

它有三个作用：

1. 缩短序列，降低后续计算量。
2. 扩大后层神经元能看到的原始范围。
3. 让特征对很小的相位偏移不那么敏感。

池化也会损失精细位置，所以local分支只有2个卷积块，避免把201点的凌星细节压缩得过度；global分支有5个块，用来整合完整周期上的大范围信息。

8. train、validation、test如何划分

为什么必须按 KIC 划分 train / validation / test



同一个 KIC 的全部季度FITS和全部TCE只能进入一个集合。

否则模型可能记住同一颗恒星的噪声、亮度变化或仪器特征，测试分数看似很高，但并没有学会泛化到新恒星。

今天的 pilot100: train 66 / validation 22 / test 22, KIC泄漏 = 0。

按KIC分组的数据划分

8.1 train训练集

每一批样本经过网络得到logit，与标签计算二元交叉熵。PyTorch反向传播梯度，Adam优化器更新9,940,193个参数。

今天保留了原论文的数据增强：训练时随机把一部分global和local序列左右翻转。一个对称或近似对称的凌星在相位方向翻转后仍应保持类别，这可以降低模型对偶然方向细节的依赖。

8.2 validation验证集

验证集不更新权重。每轮训练后在验证集计算损失、PR-AUC等指标，用它选择“最佳轮次”的模型检查点。不能根据test集反复选轮次，否则test集也参与了模型设计，最终数字会偏乐观。

8.3 test测试集

测试集应模拟模型第一次看到的新恒星。模型结构、超参数和最佳轮次都确定后，再在test集计算准确率、召回率、精确率、F1、ROC-AUC和PR-AUC。

8.4 为什么不是随机按TCE逐行切分

同一KIC的多个TCE共享相同FITS、相同恒星活动和大量相同仪器噪声。如果把一个TCE放入train、另一个放入test，模型可能识别的是这颗恒星，而不是行星凌星。

因此本项目采用5折分组：fold 0作为test，fold 1作为validation，fold 2到4作为train，并使用标签分层尽量保持正负比例。

9. 标签从哪里来

今天的监督标签使用DR25 KOI表中的 **koi_pdisposition**：

```
CANDIDATE    -> 1
FALSE POSITIVE -> 0
```

DR25共有34,032条TCE，但只有8,054条对应KOI正负标签：


标签	数量
CANDIDATE	4,034
FALSE POSITIVE	4,020
合计	8,054

这些有标签TCE涉及6,923颗唯一恒星。未标注的25,978条TCE不会在当前有监督基线中直接作为普通训练标签；它们以后可用于无监督、半监督或真正的全量搜索研究。

10. Robovetter是什么算法

Robovetter不是卷积神经网络，也不是端到端深度学习。它是Kepler团队把人工审查经验编码成的一组指标、阈值和简单决策树。

Robovetter：规则指标和决策树，而不是神经网络



AstroNet从光变形状学习权重；Robovetter由人设计指标和阈值。两者可以互补，但分数含义不同。

Robovetter的规则化判定流程

主要检查可归纳为四类：

1. **Not Transit-Like**：事件是否根本不像天体凌星，例如孤立坏点、系统噪声或不稳定的单次下降。
2. **Stellar Eclipse**：是否存在次级食、椭圆变化、过深或明显V形的食，提示食双星。
3. **Centroid Offset**：差分图像质心是否偏向邻近恒星，提示信号并非来自目标星。
4. **Ephemeris Match**：周期和历元是否与其他目标或已知污染源匹配，提示串扰或背景污染。

Robovetter把测试结果记录为major和minor flags，然后统一判为CANDIDATE或FALSE POSITIVE。

10.1 koi_score是什么意思

koi_score不是简单的“Robovetter认为是行星的物理概率”。DR25会根据指标在周期和MES上的散布随机扰动各项Robovetter指标，并重新判定10,000次。最终被判为CANDIDATE的次数比例就是score。

例如score为0.92，可以理解为指标扰动后10,000次判定中约92%仍通过候选规则。它更接近“判定对指标扰动的稳定度”。

10.2 AstroNet与Robovetter的根本区别

对比项	AstroNet	Robovetter
核心方法	可训练的1D-CNN	人工设计指标、阈值和决策树
主要输入	global/local光变形状	DV指标、光变指标、质心、周期匹配等
特征来源	从数据学习	天文学家显式设计
输出	神经网络logit和sigmoid分数	PC/FP、flags、扰动稳定度score
优点	能学习难以手写的形状组合	可解释，能利用质心和污染证据
风险	可能学到数据偏差，解释较难	阈值附近不连续，规则维护复杂

Robovetter能使用质心和星场污染等信息，而当前经典AstroNet只看两个光变视图。因此AstroNet不应被描述成对Robovetter所有能力的完整替代。

11. 今天具体做了什么

11.1 官方与参考代码核对

- 浅克隆Google Research官方 **exoplanet-ml**，固定提交用于结构和预处理核对。
- 浅克隆NASA FDL AstroNet-PyTorch，用于交叉参考。
- 按Google配置重建双分支网络。
- 检查每层输出尺寸和总参数数。

一致性检查结果：

检查项	结果
local隐藏输出	[2, 32, 46]
global隐藏输出	[2, 256, 59]
最终输出	[2]
参数数	9,940,193
local归一化	median=0, minimum=-1
global归一化	median=0, minimum=-1
PyTorch	2.12.1+cu126
GPU	RTX 3090，训练进程只可见1张


11.2 pilot100真实FITS闭环

- 100颗恒星全部完成预处理。
- 生成110个有KOI标签的TCE视图。
- train/validation/test为66/22/22。
- KIC泄漏为0。
- 其中1颗恒星触发2018年Google spline与新版pydl的数组兼容异常。
- 兼容回退仍使用官方样条函数，只把BIC多断点搜索改为固定1.5天断点，并在元数据中明确记录，避免静默改变算法。

11.3 单GPU五轮冒烟训练

本次只用于验证数据、网络、反向传播、检查点和评价代码能够闭环。66个训练样本远不足以训练近千万参数模型。

方法	准确率	精确率	召回率	F1	ROC-AUC	PR-AUC
AstroNet-PyTorch	54.55%	54.55%	100.00%	70.59%	0.7167	0.7972
DR25 Robovetter	90.91%	100.00%	83.33%	90.91%	1.0000	1.0000



pilot100上AstroNet与Robovetter的流程对照

AstroNet在0.5阈值下把22个测试样本全部判为正类，所以召回率达到100%，但10个负类全部成为假阳性。这是典型的小样本阈值塌缩，不能解读为“模型找回了所有行星”。

11.4 从100颗恒星扩展到1000颗

pilot100暴露的核心问题不是网络无法运行，而是近千万参数面对66个训练样本时几乎没有机会学到稳定的负类特征。因此M2保持网络、预处理和单卡设置不变，只把数据规模扩大约10倍，尽量把“数据量变化”与其他实验变量分开。

M2的固定范围为：

项目	数量
唯一KIC恒星	1,000
纯CANDIDATE宿主	500
纯FALSE POSITIVE宿主	500
带标签TCE	1,164
long-cadence FITS	15,569
FITS实际数据量	6,757,767,360 bytes, 约6.29 GiB
预处理失败	0
因同一KIC含正负标签而排除的混合宿主	97

CPU首先读取FITS、清理质量标记、执行官方样条去趋势、相位折叠并生成2001点global与201点local视图。视图构建每5颗恒星保存一次断点。全部1164个固定长度样本完成后，GPU 0才开始训练；这也是预处理阶段两张3090看起来空闲的原因。


训练仍使用Adam、学习率 **2e-4**、batch size 64和随机种子42，共20轮。每轮后只查看validation指标，并按照validation PR-AUC保存最佳检查点；test集在模型选择完成后才用于最终评价。

11.5 M2测试结果：模型不再全部判正

前8轮validation准确率仍约为56.65%，模型基本延续pilot100的“全部判为候选体”倾向。第9至12轮开始出现转折：训练损失继续下降，模型逐渐学会把假阳性排除出去。第19轮得到最高validation PR-AUC 0.9389，因此成为最终检查点。

在从未参与训练和选模的233个test样本上，结果为：

方法	准确率	精确率	召回率	F1	ROC-AUC	PR-AUC
AstroNet-PyTorch M2	84.12%	89.26%	81.82%	85.38%	0.9185	0.9316
DR25 Robovetter	97.00%	100.00%	94.70%	97.28%	0.9975	0.9982



M2的ROC、precision-recall曲线和AstroNet混淆矩阵

混淆矩阵可以翻译成四句话：

- 88个假阳性被正确排除，是真负类TN。
- 13个假阳性被误报为候选体，是FP。
- 24个候选体被漏掉，是FN。
- 108个候选体被正确找回，是TP。

这说明M2已经不再依靠“全部判正”取得高召回率，而是同时获得89.26%的精确率和81.82%的召回率。ROC-AUC 0.9185与PR-AUC 0.9316还说明，模型分数对两类样本已经具有较强的排序能力。

从54.55%到84.12%是明显进步，但两次实验的test样本不是同一批，不能把29.57个百分点全部解释成“数据扩大10倍的纯因果收益”。更严谨的规模实验应预先固定同一test集，再分别用100、250、500、1000颗训练恒星绘制学习曲线。

11.6 与NASA当前公共目录交叉核对：121个模型候选中有79个已确认行星

前面的准确率是模型相对于DR25历史标签的分类成绩，并不直接等于“发现了多少颗行星”。为回答更直观的问题，我们又在2026-07-14把M2的全部1164个TCE与NASA Exoplanet Archive当前KOI目录及 Planetary Systems Composite Parameters表逐项交叉核对。1164个TCE全部成功匹配，没有无法核对的条目。

先看整个1000颗宿主恒星样本的当前状态：

当前NASA状态	宿主恒星数	TCE数
至少有一颗已确认行星	313	427
只有尚未确认的候选体	182	228
只有当前假阳性	505	509
合计	1,000	1,164


再只看封存的233个test TCE。AstroNet以0.5为阈值判出了121个“值得继续检查”的模型候选；根据NASA当前目录，这121个信号由三部分组成：

NASA当前状态	数量	占121个模型候选的比例
已确认行星	79	65.29%
仍是候选体	33	27.27%
当前假阳性	9	7.44%
合计	121	100.00%

所以正确表述是：**模型判出的121个测试候选中，79个现在是已确认行星**，而不是“121个都是行星”，也不是“79颗宿主恒星”。这79个行星信号分布在54颗宿主恒星上；多行星系统的一颗恒星会贡献多个TCE。test集中一共有85个当前已确认行星信号，模型找回79个、漏掉6个，对当前确认行星的信号级召回率为 $79 / 85 = 92.94\%$ 。59颗拥有确认行星的test宿主中，54颗至少有一个信号被模型判正。

M2一千颗恒星：AstroNet与NASA当前公共目录交叉核对

注意：84.12%是233个测试TCE的分类准确率，不是行星发现率



M2样本、TCE与121个模型候选的NASA当前状态

一个很有代表性的例子是著名的Kepler-11系统（KIC 6541920）：test集中包含Kepler-11 b至g六颗行星，模型六个都判为正，分数约为0.870至0.968。整个1000颗恒星样本里还包括Kepler-444、Kepler-238、Kepler-65和Kepler-19等常见于科普或研究文献的系统。不过，这仍是对已知目标的回顾性核对，不代表

模型在本轮中首次发现了这些行星。

11.7 这79颗已确认行星离地球多远

距离采用NASA Planetary Systems Composite Parameters表中的 **sy_dist**，含义是“到这个行星系统的距离”，单位为秒差距pc。这里测量的是宿主恒星系统，不是行星绕恒星运行的轨道半径；同一个多行星系统中的各颗行星因而共享同一距离。本次79个行星条目都有距离值，无缺失。按 **1 pc = 3.26156光年** 换算：

- 最近的是Kepler-1053 b，约151.1 pc，也就是493光年。
- 距离中位数约646.3 pc，也就是2,108光年。
- Kepler-11系统约646.3 pc，即2,108光年，恰好接近本组中位数。
- 最远的是Kepler-747 b，约3,347.2 pc，也就是10,917光年。
- 79个条目中，12个在1,000光年以内，23个在1,000至2,000光年，22个在2,000至3,000光年，14个在3,000至5,000光年，5个在5,000至8,000光年，3个超过或等于8,000光年。

AstroNet找回的79个当前已确认行星：距离概览

79个行星信号来自54颗宿主恒星；距离采用NASA Exoplanet Archive的sy_dist

最近

493 光年

Kepler-1053 b

中位数

2,108 光年

一半更近，一半更远

Kepler-11系统

2,108 光年


6颗行星全部找回

最远

10,917 光年

Kepler-747 b

按距离分组（单位：光年）



换算：1 pc = 3.26156光年。这里是宿主恒星系统距离，不是模型预测值，也不是行星轨道半径。

79个已确认行星的距离分布

这些距离是NASA综合目录在本次查询时给出的近似值。该表为方便统计而汇集不同论文中的参数，同一行的不同字段可能来自不同参考文献，因此适合做本报告这种数量级说明；若要对单个系统做精密研究，还应继续查看该行的误差上下限和原始文献。完整79项明细见第17节。

12. 如何读准确率、精确率和召回率

设“候选行星”为正类：

- TP：真实正类且模型判正。
- FP：真实负类但模型判正，也叫假阳性。
- FN：真实正类但模型判负，也叫漏检。

- TN：真实负类且模型判负。

$\text{Accuracy} = (\text{TP} + \text{TN}) / \text{全部样本}$

$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$

$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$

$\text{F1} = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$

系外行星初筛通常很关心Recall，因为漏掉真实行星后可能再也不会被人工检查。但如果只追求Recall，把所有样本都判为候选体就能得到100% Recall，这显然没有实用价值。因此必须同时看Precision、PR-AUC和最终需要人工复核的候选数量。

13. 为什么当前Robovetter比较不是公平决赛

M1和M2的标签 **koi_pdisposition** 与Robovetter分数 **koi_score** 都来自DR25 Robovetter体系。于是Robovetter相当于既参与出题，又参与考试。M2中Robovetter得到97.00%准确率，不能直接解释为它在独立科学真值上必然比AstroNet高12.88个百分点。

当前比较能够回答：

- 评价代码是否正确运行。
- 同一测试集上的指标和图是否能生成。
- AstroNet对DR25标签的模仿程度如何。

它不能严格回答：

- AstroNet是否在真实天体意义上优于Robovetter。
- 哪种方法发现新行星的能力更强。
- score能否直接解释为真实行星概率。

更公平的独立测试集应组合：

- 后续得到确认的行星。
- Certified False Positives等人工认证假阳性。
- 像素级注入的已知凌星。
- 反相和打乱光变产生的已知假警报。
- 在数据划分和阈值确定后完全封存的测试集。

14. 全量监督数据有多大

已经对6,923颗有标签恒星逐个读取MAST目录，没有直接用简单乘法估算：

项目	结果
有标签TCE	8,054
唯一KIC	6,923
long-cadence FITS	107,364
MAST目录估计	46,452,401,152 bytes, 约43.26 GiB

项目	结果
舍入安全上界	46,507,371,520 bytes, 约43.31 GiB
下载硬上限	200 GiB
启动前数据盘可用	约3.2 TiB

下载器具有：

- 200 GiB硬上限。
- 50 GiB保留空间检查。
- 断点续传。
- 已有pilot100文件硬链接复用。
- FITS主头校验。
- SHA-256记录。
- 失败文件单独记录，不伪装成成功。

本轮全量下载已经完成首遍执行：107,364个计划文件中有107,353个成功落盘，实际总量46,445,137,920 bytes，约43.25 GiB；其中105,764个为新下载、1,569个复用pilot100硬链接、20个为启动前已有文件。另有11个文件因网络传输中断而失败，已保留精确清单，等待断点重试。M2选择的15,569个FITS缺失数为0，因此这11个失败文件不影响本次1000恒星结果。

15. M2之后怎样走向全量正式实验

M2证明了1000颗恒星规模下，官方预处理、分组切分和单卡训练都能稳定运行。下一阶段按以下顺序扩展：

1. 重试11个传输失败的FITS，确认107,364个文件全部成功。
2. 为8,054个有标签TCE批量生成global/local视图。
3. 统计样条回退率、空分箱率、异常值和类别分布。
4. 固定按KIC分组的train/validation/test索引并保存版本哈希。
5. 继续只使用GPU 0训练全量AstroNet基线，保持与M2可比。
6. 在validation集选择最佳轮次和分类阈值。
7. 最后一次性计算test集指标。
8. 与Robovetter在相同TCE上比较，并明确同源标签限制。
9. 生成混淆矩阵、ROC、PR曲线、分数分布和典型误判光变卡片。
10. 再引入独立确认集，进行真正有科学意义的比较。

16. 常见问题

16.1 一颗恒星是否只生成一个训练样本

不一定。训练样本的基本单位是TCE。一颗恒星若有3个不同周期的TCE，就会共享同一套FITS，但按3组周期、历元、时长分别折叠，生成3组global/local输入。

16.2 2001点和201点是不是原始观测点

不是。它们是相位折叠后通过中位数分箱得到的固定长度表示。一个位置可能聚合许多原始cadence，也可能为空；空分箱由全局中位数填充。

16.3 为什么global是奇数2001，local是奇数201

奇数长度便于把预测凌星中心放在唯一的中央位置。中心左右具有近似对称的采样位置。

16.4 双3090为什么只用一张

AstroNet只有约994万参数，单张3090显存和计算能力足够。双卡数据并行会引入额外的通信、随机性和调试变量。第一版先固定单卡，更容易证明结果可复现；第二张卡以后可以并行跑另一组独立实验。

16.5 AstroNet输出高分是否等于发现新行星

不等于。高分只表示模型认为输入形状类似训练标签中的候选体。新候选仍需检查数据质量、次级食、奇偶凌星、质心偏移、邻星污染、周期匹配和统计验证。

17. AstroNet找回的79个当前已确认行星及距离

下表按距离从近到远排列。每一行是一个已确认行星信号，不是一颗互不重复的恒星；因此Kepler-11、Kepler-235等多行星系统会出现多行。**AstroNet分数**是本次模型输出，**宿主Kp星等**是Kepler波段的视星等，数值越小表示Kepler看到的宿主恒星越亮。距离来自NASA公共目录并直接换算为光年；为节省版面，表中不再重复列出秒差距。

序号	已确认行星	宿主KIC	KOI	AstroNet分数	宿主Kp星等	约/光年
1	Kepler-1053 b	4056616	K02013.01	0.7326	13.156	493
2	Kepler-205 b	6425957	K00663.01	0.7293	13.506	521
3	Kepler-205 c	6425957	K00663.02	0.8650	13.506	521
4	Kepler-249 b	7907423	K00899.02	0.9110	15.234	621
5	Kepler-249 c	7907423	K00899.01	0.8405	15.234	621
6	Kepler-249 d	7907423	K00899.03	0.8980	15.234	621
7	Kepler-19 b	2571238	K00084.01	0.7265	11.898	713
8	Kepler-449 b	6528464	K00270.01	0.9476	11.411	789
9	Kepler-449 c	6528464	K00270.02	0.9688	11.411	789
10	Kepler-1709 b	7941200	K00092.01	0.8390	11.667	893
11	Kepler-517 b	5966322	K00303.01	0.8898	12.193	946
12	Kepler-1713 b	7670943	K00269.01	0.9676	10.927	963
13	Kepler-1026 b	4813563	K01959.01	0.9528	14.254	1,146
14	Kepler-1009 b	7094486	K01907.01	0.9265	15.278	1,158
15	Kepler-353 b	6382217	K02036.02	0.6028	15.773	1,255
16	Kepler-353 c	6382217	K02036.01	0.9130	15.773	1,255
17	Kepler-83 b	7870390	K00898.01	0.9202	15.777	1,306
18	Kepler-83 c	7870390	K00898.03	0.9229	15.777	1,306
19	Kepler-83 d	7870390	K00898.02	0.9130	15.777	1,306
20	Kepler-235 b	4139816	K00812.01	0.6173	15.954	1,396
21	Kepler-235 c	4139816	K00812.04	0.6631	15.954	1,396
22	Kepler-235 d	4139816	K00812.02	0.9336	15.954	1,396
23	Kepler-235 e	4139816	K00812.03	0.9450	15.954	1,396
24	Kepler-161 b	7440748	K00457.01	0.6921	14.196	1,418
25	Kepler-185 b	8008206	K00569.02	0.5900	14.458	1,522
26	Kepler-185 c	8008206	K00569.01	0.9307	14.458	1,522
27	Kepler-1048 b	6665512	K02005.01	0.9233	14.832	1,813
28	Kepler-1406 b	3852655	K03002.01	0.8928	13.256	1,867
29	Kepler-1470 b	4736644	K03330.01	0.8009	15.061	1,926
30	Kepler-206 b	6442340	K00664.02	0.7098	13.484	1,939
31	Kepler-206 c	6442340	K00664.01	0.9728	13.484	1,939

序号	已确认行星	宿主KIC	KOI	AstroNet分数	宿主Kp星等	约/光年
32	Kepler-206 d	6442340	K00664.03	0.8133	13.484	1,939
33	Kepler-184 b	7445445	K00567.01	0.9242	14.338	1,991
34	Kepler-184 c	7445445	K00567.02	0.9466	14.338	1,991
35	Kepler-184 d	7445445	K00567.03	0.9122	14.338	1,991
36	Kepler-1335 b	6586746	K02747.01	0.7262	15.329	2,028
37	Kepler-1601 b	2831055	K04400.01	0.8092	13.764	2,102
38	Kepler-11 b	6541920	K00157.06	0.8857	13.709	2,108
39	Kepler-11 c	6541920	K00157.01	0.9342	13.709	2,108
40	Kepler-11 d	6541920	K00157.02	0.9224	13.709	2,108
41	Kepler-11 e	6541920	K00157.03	0.8697	13.709	2,108
42	Kepler-11 f	6541920	K00157.04	0.9361	13.709	2,108
43	Kepler-11 g	6541920	K00157.05	0.9677	13.709	2,108
44	Kepler-1553 b	3955817	K04117.01	0.5498	14.955	2,259
45	Kepler-1950 b	7103919	K04310.01	0.8444	14.587	2,274
46	Kepler-1326 b	4178606	K02728.01	0.9149	12.852	2,278
47	Kepler-1205 b	6200235	K02350.01	0.5710	15.143	2,278
48	Kepler-356 b	2307415	K02053.02	0.8588	12.992	2,308
49	Kepler-356 c	2307415	K02053.01	0.9558	12.992	2,308
50	Kepler-776 b	6272413	K01129.01	0.8772	15.456	2,374
51	Kepler-559 b	8043638	K00460.01	0.9266	14.743	2,533
52	Kepler-1595 b	7427764	K04364.01	0.8000	15.448	2,756
53	Kepler-400 b	5272233	K02711.01	0.9536	13.642	2,759
54	Kepler-400 c	5272233	K02711.02	0.9355	13.642	2,759
55	Kepler-575 b	2557816	K00488.01	0.9236	14.720	2,785
56	Kepler-1457 b	6584273	K03287.01	0.9453	14.060	2,902
57	Kepler-774 b	3114811	K01117.01	0.9435	12.808	2,993
58	Kepler-160 b	7269974	K00456.02	0.9383	14.619	3,056
59	Kepler-160 c	7269974	K00456.01	0.7776	14.619	3,056
60	Kepler-397 b	6878240	K02681.02	0.6366	15.996	3,160
61	Kepler-397 c	6878240	K02681.01	0.8524	15.996	3,160
62	Kepler-798 b	6693640	K01245.01	0.9706	14.200	3,171
63	Kepler-1746 b	6766634	K01375.01	0.6738	13.709	3,195
64	Kepler-933 b	7815744	K01710.01	0.9404	15.469	3,318
65	Kepler-1824 b	5978559	K02321.01	0.9507	14.710	3,392
66	Kepler-874 b	7456001	K01517.01	0.9646	14.683	3,530
67	Kepler-1204 b	6941084	K02348.01	0.9176	15.301	3,833

序号	已确认行星	宿主KIC	KOI	AstroNet分数	宿主Kp星等	约/光年
68	Kepler-1919 b	8078502	K03383.01	0.8432	15.848	3,841
69	Kepler-1192 b	8007644	K02328.01	0.9433	15.684	4,254
70	Kepler-823 b	4135665	K01339.01	0.8515	14.801	4,531
71	Kepler-1292 b	8081905	K02619.01	0.5450	15.934	4,871
72	Kepler-754 b	2584163	K01031.01	0.8550	15.160	5,774
73	Kepler-1211 b	5602588	K02369.01	0.8705	15.832	5,957
74	Kepler-1239 b	6867555	K02439.01	0.9339	15.438	6,982
75	Kepler-896 b	7939330	K01581.02	0.9127	15.481	7,616
76	Kepler-896 c	7939330	K01581.01	0.5539	15.481	7,616
77	Kepler-1603 b	7046035	K04424.01	0.6041	15.332	8,847
78	Kepler-717 b	7685981	K00893.01	0.8413	15.662	9,150
79	Kepler-747 b	5780460	K01005.01	0.8230	15.703	10,917

18. 资料来源

- Shallue & Vanderburg, AstroNet原论文: [Identifying Exoplanets with Deep Learning](#)
- Google Research官方源码: [google-research/exoplanet-ml](#)
- NASA FDL PyTorch参考实现: [AstroNet-PyTorch](#)
- Thompson et al. DR25目录与Robovetter论文: [Planetary Candidates Observed by Kepler VIII](#)
- NASA Exoplanet Archive DR25说明: [Q1-Q17 DR25 KOI Companion](#)
- NASA Exoplanet Archive数据产品概览: [Kepler Data Products Overview](#)
- NASA Exoplanet Archive行星系统参数字段说明 (**sy_dist**定义): [Planetary Systems and Composite Parameters Column Definitions](#)
- NASA Exoplanet Archive综合参数表说明: [About the Planetary Systems Composite Parameters Table](#)
- NASA Exoplanet Archive综合参数计算说明: [Calculated Parameters in PSCompPars](#)

本文中的数值结果来自本机和E5远端项目在2026-07-14的实际执行记录；NASA当前状态和距离也是当日查询快照。pilot100只证明流程闭环；M2证明模型在1000颗恒星上已经学到有效区分能力，但仍属于对DR25标签的一次复现。正式科学结论还需要全量学习曲线、固定独立测试集和独立标签评估。